ELMo (Embedding from Language Model)

송지수

목치


- 1. ELMo Introduction
- 2. ELMo 소개
- 3. Evaluation

ELMo Introduction

일모?


- Embedding from Language Model
- 기존의 Word Embedding 기법인 Word2Vec, FastText 등은 문맥에 관계 없이 단어 당 벡터 하나로 Embedding 됨
- ELMo는 단어를 Vectorization 하는 과정에서 주변 단어를 고려, 같은 단어라도 문맥에 따라 다른 Vector를 가지게 됨

Word2Vec, FastText, ...



- Skip-gram 혹은 CBOW (주로 Skip-gram)
- 주변 단어의 분포를 통해 중심 단어의 출현 확률을 학습
- 함께 출현한 단어들 간의 유사도는 높이고,
 함께 출현하지 않은 단어들 간의 유사도는 낮추는
 방향으로 학습이 진행
- 결과물은 "임베딩 단어 벡터"


Then How About ELMo




- biLSTM Layer의 Layer Representations의 Combination이 결과물
- Inference를 위한 Input이 Word가 아닌 'Sentence'
- 따라서 모델에 들어가는 Sequence length 만큼의 맥락을 고려하여 Vectorization 가능

ELMo 소개

Training





- ELMo의 Input을 Character로 넣을 건지, Word로 넣을 것인지는 선택 가능 (TF 구현체 참고)
- Character로 Input을 준다면 token layer에서
 Character CNN 사용
- Word로 Input을 준다면, 미리 Embedding 된 자료 필요

Training

$$p(t_1,t_2,\ldots,t_N) = \prod_{k=1}^N p(t_k \mid t_1,t_2,\ldots,t_{k-1})$$
. • t1, t2, \ldots , tk-1 로 tk가 나타날 확률을 예측


< Forward >

$$p(t_1,t_2,\ldots,t_N) = \prod_{k=1}^N p(t_k \mid t_{k+1},t_{k+2},\ldots,t_N)$$
. • tk+1, tk+2, ..., tN 으로 tk가 나타날 확률을 예측

< Backward >

Training

$$\sum_{k=1}^{N} \left(\log p(t_k \mid t_1, \dots, t_{k-1}; \Theta_x, \overrightarrow{\Theta}_{LSTM}, \Theta_s) + \log p(t_k \mid t_{k+1}, \dots, t_N; \Theta_x, \overleftarrow{\Theta}_{LSTM}, \Theta_s) \right).$$




- biLM은 Forward와 Backward의 loglikelihood를 합하고, 그를 maximize 하는 방 향으로 학습
- 이는 다음 biLSTM Layer의 Input이 됨

ELMo는 뭘 뱉나요

$$R_k = \{\mathbf{x}_k^{LM}, \overrightarrow{\mathbf{h}}_k^{LM,j}, \overleftarrow{\mathbf{h}}_k^{LM,j} \mid j = 1, \dots, L\} = \{\mathbf{h}_k^{LM,j} \mid j = 0, \dots, L\},\$$

- L: biLM의 레이어 수
- $\mathbf{h}_{k}^{LM,0}$: token layer
- $\mathbf{h}_{k}^{LM,j}$: each biLSTM layer
- 각 token마다, 각 biLSTM layer의 Representation을 얻고 그 Representation들을 조합해 최종 벡터를 반환

ELMo는 뭘 뱉나요



• s = Softmax(w)

• γ : Vector Scale을 결정하는 상수

$$E(R_k; \mathbf{w}, \gamma) = \gamma \sum_{j=0}^{L} s_j \mathbf{h}_k^{LM, j}.$$

Evaluation

얼마나좋은가요

TASK	PREVIOUS SOTA		OUR BASELINE	ELMO + BASELINE	INCREASE (ABSOLUTE/ RELATIVE)
SNLI	McCann et al. (2017)	88.1	88.0	88.7 ± 0.17	0.7 / 5.8%
$SQuAD^2$	r-net Wang et al. (2017)	84.3	81.1	85.3	4.2 / 22.2%
SRL	He et al. (2017)	81.7	81.4	84.6	3.2 / 17.2%
Coref	Lee et al. (2017)	67.2	67.2	70.4	3.2 / 9.8%
NER	Peters et al. (2017)	91.93 ± 0.19	90.15	92.22 ± 0.10	2.06 / 21%
SST-5	McCann et al. (2017)	53.7	51.4	54.7 ± 0.5	3.3 / 6.8%

Question Answering, Semantic Role Labeling, Sentiment Analysis 등의 대부분 NLP Task에서 성능 향상을 보임

얼마나좋은가요

Table 4: Nearest neighbors to "play" using GloVe and the context embeddings from a biLM.

	Source	Nearest Neighbors
GloVe	play playing, game, games, played, players, plays, play Play, football, multiplayer	
biLM	Chico Ruiz made a spectacular play on Alusik 's grounder {} Olivia De Havilland signed to do a Broadway	Kieffer, the only junior in the group, was commended for his ability to hit in the clutch, as well as his all-round excellent play. [] they were actors who had been handed fat roles in a successful play, and had talent enough to fill the
	play for Garson $\{\dots\}$	roles competently, with nice understatement.

문맥에 따라 같은 단어라도 다른 Vector로 Embedding 되는 것을 확인 가능



감사합니다!